

ĐẠI HỌC CÔNG NGHỆ TP.HCM — HUTECH



Đề Xuất Hướng Đồ Án Chuyên Ngành

Phát triển từ nền tảng KidFun V2 — Hệ thống kiểm soát thời gian sử dụng thiết bị thông minh cho trẻ em

DỰ ÁN NỀN TẢNG

KidFun V2.0

NHÓM

Nhóm 60

SỐ ĐỀ TÀI ĐỀ XUẤT

4 Hướng

HỌC KỲ

Đồ án chuyên ngành



Tổng Quan Project Nền Tảng

KidFun V2 — Smart Parental Control System

KidFun V2 là hệ thống kiểm soát thời gian sử dụng thiết bị thông minh dành cho trẻ em, giúp phụ huynh quản lý và giám sát toàn diện hoạt động số của con em. Hệ thống đã được phát triển đến Sprint 9 với kiến trúc đa nền tảng bao gồm Backend API, Parent Dashboard (Electron/React), Child Monitor (Electron/React), và Mobile App (Flutter). Đây là nền tảng kỹ thuật vững chắc để phát triển lên đồ án chuyên ngành.

❑ KIẾN TRÚC HỆ THỐNG

Backend: Node.js + Express + Prisma ORM + PostgreSQL + Socket.IO

Desktop: Electron + React 19 + Material UI v7

Mobile: Flutter + Riverpod + Firebase

AI: Groq API + OpenRouter (Llama 4)

❑ CÁC TÍNH NĂNG ĐÃ CÓ

Quản lý thời gian

Chặn website/app

YouTube monitoring

AI content analysis

GPS & Geofencing

SOS Alert

School Mode

Real-time Socket.IO

FCM Notifications

Báo cáo thống kê

❑ DỮ LIỆU HÀNH VI CÓ SẴN (DATABASE MODELS)

AppUsageLog

UsageSession

YouTubeLog + AIAAlert

LocationLog

GeofenceEvent

ReportSnapshot

TimeExtensionRequest

SOSAlert

Warning

❑ TECH STACK

Node.js / Express

PostgreSQL

React 19

Flutter

Socket.IO

Firebase / FCM

Groq AI

Electron

Mapbox

Prisma ORM

● Điểm mạnh làm nền tảng cho đồ án chuyên ngành

- ❑ **Dữ liệu đa chiều thực tế** — Screen time, Location, Content Safety, SOS, Geofence events
- ❑ **AI đã tích hợp sẵn** — aiService.js với Groq + OpenRouter, phân tích nội dung YouTube
- ❑ **Cơ sở dữ liệu 25+ models** — phong phú cho Data Mining & Analytics
- ❑ **Kiến trúc microservice-ready** — dễ dàng thêm module AI/DW mới
- ❑ **Real-world context** — bài toán thực tiễn, có giá trị xã hội rõ ràng

□ Định hướng mở rộng

Các đề tài sau **kế thừa toàn bộ hạ tầng KidFun V2** và bổ sung các module chuyên sâu mới. Cách tiếp cận này giúp tiết kiệm thời gian xây dựng nền tảng, tập trung vào nghiên cứu chuyên sâu, và có thể demo sản phẩm thực tế ngay từ đầu.

Hệ thống Phân tích và Dự đoán Hành vi Sử dụng Thiết bị của Trẻ em bằng Machine Learning

"Từ dữ liệu hành vi thực tế → mô hình học máy → cảnh báo thông minh cho phụ huynh"

HỌC THUẬT

□□□□

THỰC TIỄN

□□□□□

ĐỘ KHÓ

Trung bình

KHUYẾN NGHỊ

□ **Tốt nhất**

● Mô Tả Bài Toán

Hành vi sử dụng thiết bị của trẻ em mang tính **chu kỳ và có pattern rõ ràng** (ngày thường vs cuối tuần, giờ học vs giờ chơi, mùa thi vs nghỉ hè). Hệ thống hiện tại của KidFun V2 chỉ phản ứng *sau khi* trẻ vi phạm giới hạn. Bài toán nghiên cứu đặt ra là: **"Liệu có thể dự đoán trước khi nào trẻ có nguy cơ vi phạm giới hạn và đưa ra cảnh báo thông minh cho phụ huynh?"** Bên cạnh đó, việc phát hiện các hành vi bất thường (anomaly) trong lịch sử sử dụng cũng mang giá trị bảo vệ trẻ em cao.

● □ Ý Tưởng / Giải Pháp Đề Xuất

Giải pháp đề xuất là xây dựng một **AI Microservice** viết bằng Python (FastAPI) chạy song song với backend Node.js hiện có của KidFun V2. Microservice này consume dữ liệu hành vi từ PostgreSQL (AppUsageLog, UsageSession, YouTubeLog...), tiền xử lý thành feature vectors, rồi huấn luyện và phục vụ (serve) các model ML theo hai chế độ:

□ Offline Batch (Mỗi đêm)

Node-cron trigger lúc 00:00 → gọi FastAPI → model dự đoán nguy cơ ngày hôm sau → lưu kết quả vào DB → sáng sớm phụ huynh nhận FCM push notification với insight.

⚡ Online Real-time (Trong phiên)

Mỗi khi child heartbeat → backend kiểm tra anomaly score → nếu vượt ngưỡng → emit Socket.IO event → phụ huynh nhận cảnh báo ngay tức thì trong app.

Phụ huynh tương tác với kết quả AI thông qua tab **"AI Insights"** mới trong Parent Dashboard (React), hiển thị prediction chart, anomaly heatmap theo giờ/ngày, và danh sách gợi ý thông minh được cá nhân hóa theo từng profile trẻ.

● Dữ liệu đầu vào

- AppUsageLog — thời gian dùng app theo ngày
- UsageSession — phiên sử dụng
- TimeExtensionRequest — lịch sử xin thêm giờ
- Warning — lịch sử cảnh báo đã gửi
- GeofenceEvent — vị trí trẻ theo thời gian
- Ngày trong tuần, giờ trong ngày, loại app

● Đầu ra / Kết quả

- Dự đoán % khả năng vượt giới hạn ngày mai
- Phát hiện hành vi bất thường (anomaly score)
- Phân tích xu hướng tuần/tháng
- Gợi ý điều chỉnh giới hạn thời gian
- Dashboard AI insights cho phụ huynh



Đề Tài 01 — Chi Tiết Kỹ Thuật

AI Behavior Analysis & Prediction

• Các Module Nghiên Cứu Chính

Module 1 — Screen Time Prediction (Dự đoán thời gian sử dụng)

Xây dựng mô hình dự đoán thời gian sử dụng thiết bị cho ngày hôm sau dựa trên lịch sử 30-90 ngày. Áp dụng phương pháp time series forecasting. Phụ huynh nhận cảnh báo từ đêm hôm trước nếu ngày mai có nguy cơ cao trẻ vượt giới hạn.

LSTM Neural Network

Prophet (Meta)

XGBoost

Python + scikit-learn

FastAPI microservice

Module 2 — Anomaly Detection (Phát hiện hành vi bất thường)

Phát hiện các hành vi bất thường trong pattern sử dụng: mở app lạ lúc nửa đêm, thay đổi đột ngột trong thói quen sử dụng, tăng đột biến thời gian xem nội dung nguy hiểm. Kết hợp với AI content safety score từ YouTubeLog để tạo cảnh báo tổng hợp.

Isolation Forest

DBSCAN Clustering

Autoencoder (PyTorch)

Real-time alerting

Module 3 — Behavior Pattern Mining (Khai thác mẫu hành vi)

Phân tích và khai thác pattern hành vi theo nhiều chiều: thói quen theo ngày trong tuần, app được dùng nhiều nhất theo khung giờ, tương quan giữa vị trí địa lý và thời gian sử dụng, mối liên hệ giữa School Mode và thói quen sau giờ học.

K-Means Clustering

Association Rules (Apriori)

Heatmap visualization

Module 4 — Smart Recommendation Engine (Gợi ý thông minh)

Dựa trên lịch sử hành vi và kết quả phân tích, hệ thống đưa ra các gợi ý cụ thể cho phụ huynh: điều chỉnh time limit theo từng ngày, danh sách website/app nên chặn thêm, thời điểm tốt nhất để áp dụng School Mode, so sánh với khuyến nghị của WHO về screen time.

Collaborative Filtering

Rule-based Engine

WHO guidelines integration

• Tính Novelty Học Thuật

- N1** Dataset thực từ hệ thống vận hành thật (không phải synthetic)
- N2** Kết hợp đa nguồn dữ liệu: screen time + GPS + content safety
- N3** Bài toán "child screen behavior prediction" — ít paper tại Việt Nam

• Tech Stack Bổ Sung

AI/ML: Python, PyTorch / TensorFlow, scikit-learn, pandas, numpy

API: FastAPI (microservice AI) tích hợp với Node.js hiện có

Visualization: Recharts (có sẵn) + D3.js cho heatmap

N4 Tích hợp anomaly detection vào hệ thống parental control real-time

Scheduler: Node-cron → gọi AI microservice mỗi đêm

Database: PostgreSQL (OLTP) + feature store cho ML

Thiết kế và Triển khai Data Warehouse cho Hệ thống Giám sát Thiết bị Trẻ em

"Phân tích đa chiều hành vi sử dụng — từ OLTP sang OLAP để đưa ra insights chiến lược"

HỌC THUẬT

□□□□

THỰC TIỄN

□□□□

ĐỘ KHÓ

Trung bình

PHÙ HỢP GV

Data/DW/DB

● Mô Tả Bài Toán

Hệ thống KidFun V2 hiện dùng cơ sở dữ liệu OLTP (PostgreSQL) được thiết kế cho giao dịch real-time — **không phù hợp cho phân tích xu hướng dài hạn** trên nhiều user. Khi hệ thống scale lên hàng nghìn gia đình, việc chạy báo cáo analytics trên OLTP sẽ gây chậm hệ thống và thiếu linh hoạt. Bài toán đặt ra là: **"Thiết kế Data Warehouse riêng với Star Schema, xây dựng ETL pipeline tự động, và phát triển dashboard phân tích đa chiều (OLAP) cho phụ huynh và nhà nghiên cứu."**

● □ Ý Tưởng / Giải Pháp Đề Xuất

Giải pháp là thiết kế một **PostgreSQL DW schema riêng biệt** (schema dw_*) chạy song song với OLTP schema hiện tại, không can thiệp vào dữ liệu giao dịch. Hệ thống hoạt động theo 3 tầng:

□ Tầng ETL

Node.js cron job chạy lúc 01:00 mỗi đêm, đọc dữ liệu OLTP từ 24h qua, aggregate, làm sạch và enrich (thêm category, risk level), rồi upsert vào các Fact/Dim tables.

□ Tầng DW (Star Schema)

2 Fact tables (FactScreenUsage, FactYouTubeActivity) + 5 Dimension tables (DimDate, DimProfile, DimApp, DimContentRisk, DimLocation). Tối ưu cho

□ Tầng Analytics

REST API riêng (/api/analytics/*) phục vụ OLAP queries. Parent Dashboard bổ sung tab Analytics với drill-down charts, heatmap giờ sử dụng, và so sánh chuẩn WHO.

OLAP queries với index chiến lược.

Điểm đặc biệt: DW tích hợp dimension **DimContentRisk** (AI-generated từ aiService.js) — cho phép phân tích tương quan giữa screen time, vị trí địa lý và mức độ rủi ro nội dung trong một OLAP query duy nhất.

● Nguồn dữ liệu (OLTP)

- AppUsageLog — screen time theo app
- UsageSession — phiên sử dụng
- YouTubeLog + AIAalert — nội dung & rủi ro
- LocationLog + GeofenceEvent
- TimeExtensionRequest
- Profile + Device + User (dimensions)

● Đầu ra / Kết quả

- Data Warehouse với Star Schema hoàn chỉnh
- ETL Pipeline tự động (hàng đêm)
- OLAP Cube cho drill-down, slice, dice
- Dashboard analytics nâng cao
- Cross-family aggregate reports (ẩn danh)




Đề Tài 02 — Chi Tiết Kỹ Thuật

Data Warehouse Design & OLAP Analytics

Star Schema — Thiết kế Data Warehouse

Table	Loại	Mô tả & Các trường chính
FactScreenUsage	FACT	profileId, deviceId, appId, dateId, locationId, durationSeconds, contentRiskScore, isViolation
FactYouTubeActivity	FACT	profileId, dateId, channelId, videoCount, totalDurationSecs, avgDangerLevel, blockedCount
DimDate	DIM	dateId, date, dayOfWeek, weekNumber, month, year, isWeekend, isHoliday, isSchoolDay
DimProfile	DIM	profileId, ageGroup (0-6, 7-12, 13-15), gender, hasSchoolMode
DimApp	DIM	appId, packageName, appName, category (Education/Game/Social/Video...), isBlocked
DimContentRisk	DIM	riskId, dangerLevel (1-5), category (SAFE/BULLY/SEXUAL...), aiProvider
DimLocation	DIM	locationId, geofenceName, locationType (Home/School/Other), isInGeofence

ETL Pipeline — Luồng xử lý dữ liệu



ETL chạy tự động mỗi nửa đêm, đảm bảo dữ liệu analytics luôn fresh cho báo cáo hàng ngày.

OLAP Queries — Phân tích đa chiều

Tính Novelty Học Thuật

- **Drill-down:** Tổng thời gian → Theo tuần → Theo ngày → Theo giờ
- **Slice:** Lọc theo nhóm tuổi trẻ / loại app / mức rủi ro nội dung
- **Dice:** Chéo giữa vị trí địa lý và thời gian sử dụng
- **Roll-up:** Báo cáo tổng hợp theo tháng/quý
- **Pivot:** So sánh ngày trong tuần với cuối tuần

- N1** Tích hợp dimension "Content Risk" (AI-generated) vào DW truyền thống
- N2** Ứng dụng DW vào lĩnh vực Child Digital Wellbeing — rất ít nghiên cứu
- N3** Cross-family aggregate analytics (ẩn danh) — xu hướng toàn vùng
- N4** So sánh với chuẩn WHO screen time recommendation theo nhóm tuổi

Ứng dụng Federated Learning trong Phân tích Hành vi Thiết bị đảm bảo Quyền Riêng tư Trẻ em

"Train AI model trên dữ liệu nhạy cảm của trẻ em mà không cần upload dữ liệu lên server"

HỌC THUẬT

□□□□□

THỰC TIỄN

□□□

ĐỘ KHÓ

Cao

NOVELTY

Rất cao □

● Mô Tả Bài Toán

Dữ liệu hành vi của trẻ em là **cực kỳ nhạy cảm về quyền riêng tư**. Các quy định quốc tế như COPPA (Mỹ), GDPR-K (EU) đặt ra yêu cầu nghiêm ngặt về thu thập và xử lý dữ liệu trẻ em. Nếu muốn train mô hình AI từ dữ liệu nhiều gia đình để có accuracy cao hơn, cần giải quyết mâu thuẫn: **"Làm sao cải thiện độ chính xác của AI mà không vi phạm quyền riêng tư?"** Federated Learning (FL) là câu trả lời — mỗi thiết bị chỉ gửi *gradient updates* lên server, dữ liệu thô không bao giờ rời khỏi máy.

● □ Ý Tưởng / Giải Pháp Đề Xuất

Giải pháp là triển khai **Federated Learning theo kiến trúc client-server**, trong đó Flutter mobile app đóng vai trò FL Client và một FL Aggregation Server mới (Python + Flower framework) được thêm vào hệ thống. Toàn bộ luồng hoạt động như sau:

□ Phía Client (Flutter App)

Tích hợp TensorFlow Lite. Mỗi tuần, app lấy global model về, train trên AppUsageLog cục bộ (on-device), áp dụng Differential Privacy (Gaussian noise) vào gradient, rồi upload gradient (không phải raw data) lên FL Server qua gRPC.

□ Phía Server (FL Aggregator)

Python + Flower framework nhận gradient từ N thiết bị (tối thiểu 3), chạy thuật toán FedAvg, tạo global model mới. Sau mỗi round, đánh giá accuracy và privacy budget (ϵ , δ). Broadcast global model về tất cả clients.

Nghiên cứu tập trung vào **đánh giá trade-off** giữa accuracy của FL model vs centralized model, và chi phí privacy (privacy budget ϵ) — đây là đóng góp học thuật chính của đề tài. Có thể simulate multi-client bằng cách phân vùng (partition) dataset thực từ PostgreSQL thành nhiều client giả lập nếu chưa đủ user thật.

● Kiến trúc FL

- Mỗi thiết bị: train local model
- Server: nhận gradient, aggregate (FedAvg)
- Global model cải thiện qua mỗi round
- Dữ liệu thô không bao giờ upload
- Áp dụng Differential Privacy (noise injection)

● Usecase trong KidFun

- Phát hiện hành vi bất thường (on-device)
- Cải thiện AI content risk model
- Dự đoán thời gian sử dụng cá nhân hóa
- So sánh behavioral pattern ẩn danh



Đề Tài 03 — Chi Tiết Kỹ Thuật

Federated Learning & Privacy-Preserving Analytics

● Kiến trúc Hệ thống Federated Learning

```
[Thiết bị A] → Local train (AppUsageLog riêng) → gradient_A
[Thiết bị B] → Local train (AppUsageLog riêng) → gradient_B
[Thiết bị C] → Local train (AppUsageLog riêng) → gradient_C
      ↓ ↓ ↓ (gửi gradient, KHÔNG gửi data thô)
[FL Server] → FedAvg(gradient_A, B, C) → global_model_v2
      ↓ (broadcast global model về các thiết bị)
[Thiết bị A/B/C] → Update local model → round tiếp theo
```

Module 1 — On-Device Local Training

Triển khai lightweight ML model chạy trên Flutter mobile app (TensorFlow Lite / ONNX). Model train trên AppUsageLog, UsageSession của chính thiết bị đó để học behavior pattern cá nhân. Áp dụng kỹ thuật model compression để model chạy được trên mobile.

TensorFlow Lite

ONNX Runtime

Flutter + Dart

Model Quantization

Module 2 — Federated Aggregation Server

Server nhận gradient updates từ các thiết bị, áp dụng thuật toán FedAvg (Federated Averaging) để tổng hợp thành global model mới. Thêm Differential Privacy (Gaussian noise) vào gradient trước khi gửi để bảo vệ quyền riêng tư thêm một lớp nữa.

FedAvg Algorithm

Differential Privacy

Python + PySyft / Flower

gRPC communication

Module 3 — Privacy Evaluation & Metrics

Đánh giá mức độ bảo vệ quyền riêng tư qua các metric: Privacy Loss Budget (ϵ , δ), so sánh accuracy của FL model vs centralized model, đo lường communication cost, và thực hiện membership inference attack để kiểm chứng độ bảo mật.

Privacy Budget (ϵ , δ)

Membership Inference Test

Accuracy vs Privacy Trade-off

● Tính Novelty Học Thuật

N1 FL cho bài toán Child Safety — chưa có nghiên cứu Việt Nam

● Lưu ý & Thách thức

⚠ Cần nhiều "devices" để FL có nghĩa — cần simulate nhiều thiết bị hoặc có user thật

- N2** Kết hợp Differential Privacy + FL cho dữ liệu trẻ em (COPPA compliance)
- N3** Cross-device FL trên kiến trúc heterogeneous (Android + iOS + Desktop)
- N4** Phù hợp submit hội nghị IEEE/ACM về Privacy & Security

⚠ **Độ phức tạp kỹ thuật cao** — phù hợp nếu có GV hướng dẫn về ML/Security

⚠ **Communication overhead** — cần thiết kế careful để mobile không tốn pin

☐ **Có thể simulate** bằng cách chia dataset thành nhiều partition giả lập multi-client

Hệ thống Kiểm duyệt Nội dung Đa phương thức cho Trẻ em sử dụng LLM & Computer Vision

"Phân tích đồng thời hình ảnh thumbnail, tiêu đề, kênh và transcript để đánh giá nội dung chính xác hơn"

HỌC THUẬT

□□□□

THỰC TIỄN

□□□□□

ĐỘ KHÓ

Trung bình-Cao

DEMO

Ấn tượng nhất

● Mô Tả Bài Toán

AI phân tích nội dung YouTube hiện tại trong KidFun V2 (Sprint 9) chỉ dựa trên **title và channel name** — đây là thông tin rất hạn chế và dễ bị mislead (nhiều video nguy hiểm có title vô hại).

Bài toán đặt ra: **"Xây dựng hệ thống phân tích nội dung đa phương thức (multimodal) kết hợp phân tích hình ảnh thumbnail (Computer Vision), nội dung tiêu đề/mô tả (NLP), và transcript audio để đánh giá độ an toàn chính xác và giải thích được."** Thêm vào đó, bổ sung tính năng Explainable AI để phụ huynh hiểu *tại sao* video bị đánh giá nguy hiểm.

● □ Ý Tưởng / Giải Pháp Đề Xuất

Giải pháp là thay thế aiService.js hiện tại (single-modal: chỉ text) bằng một **Multimodal AI Pipeline** gồm 4 giai đoạn xử lý song song, sau đó fusion lại bằng ensemble model:

□ Giai đoạn 1 — Vision

Download thumbnail → CLIP model encode thành embedding → so sánh với danger template library → Vision Risk Score (0-1).

□ Giai đoạn 2 — NLP

Phân tích title + description + tags bằng PhoBERT fine-tuned cho child safety → Text Risk Score. Phát hiện toxic language theo ngữ cảnh, không chỉ keyword matching.

□ Giai đoạn 3 — Transcript

□ Giai đoạn 4 — Fusion + XAI

Fetch YouTube Captions (CC) hoặc dùng
Whisper ASR → tóm tắt bằng LLM → phân tích
nội dung âm thanh → Audio Content Score.

Weighted ensemble 3 scores → Final Risk
Score (0-100). LIME/SHAP tạo explanation
JSON. Grad-CAM highlight vùng nguy hiểm
trên thumbnail → hiển thị cho phụ huynh.

Toàn bộ pipeline chạy async sau khi YouTubeLog được tạo, kết quả lưu vào
YouTubeLog.aiSummary và AIAIalert với explanation field mới. Parent Dashboard hiển thị panel
XAI: thumbnail với heatmap overlay, contribution bar chart theo từng signal, và lý do bằng tiếng
Việt dễ hiểu cho phụ huynh không chuyên kỹ thuật.

● Vấn đề với AI hiện tại

- Chỉ phân tích title + channel → accuracy thấp
- Thumbnail chứa nhiều clue quan trọng bị bỏ qua
- Không có transcript analysis
- Không giải thích được lý do (black-box)
- Không học từ feedback của phụ huynh

● Cải tiến đề xuất

- Vision-Language Model: phân tích thumbnail
- NLP pipeline: title + description + tags
- Transcript: YouTube CC/ASR analysis
- Multi-signal fusion: kết hợp tất cả signals
- XAI: giải thích từng yếu tố tác động



Đề Tài 04 — Chi Tiết Kỹ Thuật

Multimodal AI Content Moderation System

Module 1 — Vision Analysis (Phân tích hình ảnh thumbnail)

Sử dụng Vision-Language Model để phân tích thumbnail YouTube. Model sẽ nhận diện: biểu cảm khuôn mặt bất thường, màu sắc clickbait, hình ảnh bạo lực/gợi cảm, symbol nguy hiểm. Kết hợp CLIP (OpenAI) để so sánh similarity giữa thumbnail và các template nguy hiểm đã biết.

CLIP (OpenAI)

LLaVA (Vision-Language)

Gemini Vision API

Python + FastAPI

Module 2 — NLP Pipeline (Phân tích văn bản đa nguồn)

Pipeline xử lý ngôn ngữ tự nhiên trên nhiều nguồn văn bản: video title, description, tags, comment top 10. Sử dụng fine-tuned BERT/PhoBERT cho tiếng Việt để phân loại nội dung. Phát hiện từ ngữ độc hại, ngôn từ không phù hợp với trẻ em theo ngữ cảnh (không chỉ keyword matching).

PhoBERT (Tiếng Việt)

mBERT Multilingual

HuggingFace Transformers

Toxic Comment Classification

Module 3 — Multi-signal Fusion & Scoring

Kết hợp kết quả từ Vision Analysis + NLP Pipeline + metadata (viewCount, likeRatio, channelAge) thành một risk score tổng hợp bằng weighted ensemble model. Mỗi signal được gán trọng số dựa trên validation accuracy trên test set. Kết quả là Risk Score từ 0-100 thay vì chỉ level 1-5.

Weighted Ensemble

Late Fusion Architecture

Calibrated Probability

Module 4 — Explainable AI (XAI) cho Phụ huynh

Thay vì chỉ nói "Video này nguy hiểm mức 4/5", hệ thống giải thích chi tiết: "Thumbnail chứa hình ảnh bạo lực (60% contribution), tiêu đề sử dụng từ ngữ không phù hợp (30%), kênh có lịch sử vi phạm (10%)". Dùng LIME/SHAP để generate explanation cho từng prediction. Highlight region nguy hiểm trên thumbnail bằng Grad-CAM heatmap.

LIME / SHAP

Grad-CAM Visualization

Contribution Attribution

● Tính Novelty Học Thuật

- N1** Multimodal content safety cho YouTube tiếng Việt — dataset thiếu
- N2** XAI cho parental control — giải thích AI quyết định cho non-expert
- N3** Fine-tune PhoBERT cho child safety classification (tiếng Việt)

● Kế thừa từ KidFun V2

- ☐ **aiService.js** → Nâng cấp từ single-modal lên multimodal
- ☐ **YouTubeLog model** → Thêm field thumbnailAnalysis, transcript
- ☐ **AIAlert model** → Thêm explanation JSON field
- ☐ **Parent Dashboard** → Thêm XAI panel hiển

N4 Tích hợp thực tế: model chạy trực tiếp trong hệ thống thật

thị

□ **youtubeController.js** → Gọi multimodal AI pipeline



So Sánh Tổng Quan & Kết Luận

Đánh giá 4 hướng đề tài để lựa chọn phù hợp nhất

Tiêu chí đánh giá	Đề tài 01 AI Behavior	Đề tài 02 Data Warehouse	Đề tài 03 Federated	Đề tài 04 Multimodal AI
☐ Tính học thuật	★★★★	★★★★	★★★★★	★★★★
☐ Tính ứng dụng thực tiễn	★★★★★	★★★★	★★★	★★★★★
☐ Độ khó triển khai	Trung bình	Trung bình	Cao	Trung bình-Cao
☐ Kế thừa từ KidFun V2	Rất tốt ☐	Tốt ☐	Tốt ☐	Rất tốt ☐
☐ Dữ liệu có sẵn	☐ Ngay lập tức	☐ Ngay lập tức	⚠ Cần nhiều user	☐ Ngay lập tức
☐ Demo ấn tượng	★★★★	★★★	★★★	★★★★★
☐ Viết báo cáo học thuật	★★★★	★★★★	★★★★★	★★★★
☒ GV phù hợp	AI/ML/Data Mining	DW/DB/Big Data	AI/Security/Privacy	AI/CV/NLP

☐ Khuyến nghị từ phân tích

Đề tài 01 (AI Behavior Analysis) được đánh giá là **cân bằng nhất** giữa học thuật và thực tiễn. Dữ liệu AppUsageLog, UsageSession đã có sẵn và phong phú, bài toán có giá trị xã hội rõ ràng, kết quả có thể demo trực quan và thuyết phục GV. Python ML + FastAPI microservice dễ tích hợp vào backend Node.js hiện có mà không phá vỡ kiến trúc.

Đề tài 04 (Multimodal AI) nếu muốn demo ấn tượng nhất và đã có kinh nghiệm về CV/NLP. Kế thừa trực tiếp aiService.js của Sprint 9 và nâng cấp lên đáng kể.

1. Thầy/Cô có hướng nghiên cứu nào ưu tiên (AI, DW, Security, CV/NLP) không để em có thể align topic cho phù hợp?
2. Đồ án chuyên ngành có yêu cầu viết báo cáo theo dạng research paper không?
3. Có cần dataset thực hay có thể dùng data sinh bởi hệ thống tự vận hành?
4. Thầy/Cô có lab hoặc nhóm nghiên cứu liên quan đến chủ đề này không?

Pitch gợi ý cho GV:

"Em có project KidFun V2 — hệ thống parental control với dữ liệu hành vi trẻ em đa chiều (screen time, GPS, YouTube, AI content analysis). Em muốn nâng cấp lên đồ án chuyên ngành bằng cách bổ sung [Hướng X] để giải quyết bài toán [Y]. Dataset thực đã có sẵn từ hệ thống, giúp em tập trung vào nghiên cứu chuyên sâu thay vì xây dựng lại từ đầu."

□ Dữ liệu hiện có — Lợi thế cạnh tranh của KidFun V2

KidFun V2 đã có **25+ database models, AI service tích hợp Groq + OpenRouter, Firebase/FCM push notifications, GPS Geofencing, YouTube monitoring** và **ReportSnapshot pipeline**. Đây là lợi thế rất lớn so với các nhóm bắt đầu từ đầu — bạn có thể dành toàn bộ thời gian đồ án chuyên ngành cho phần *nghiên cứu* thay vì phần *xây dựng hạ tầng*.